REGISTRO DE IA - SEMANA 23

Integrando RAG e memória de curto prazo ao Agente de Dúvidas

Parte 1 — Criando a coleção de documentos

documentos = [{ "titulo": "Estruturas de repetição", "conteudo": "Estruturas de repetição permitem executar comandos várias vezes." }, { "titulo": "Python", "conteudo": "Python é uma linguagem usada em IA." }]

Parte 2 — Criando a recuperação de contexto

def recuperar_documento(pergunta): pergunta = pergunta.lower() documento_relevante = None for doc in documentos: if doc["titulo"].lower() in pergunta: documento_relevante = doc["conteudo"] return documento_relevante

Parte 3 — Criando a memória da conversa

historico_conversa = []

Parte 4 — Integrando ao agente

import jsonclass AgenteDuvidas: def responder(self, pergunta): contexto = recuperar_documento(pergunta) historico_conversa.append(pergunta) with open("memoria.json", "w") as arquivo: json.dump(historico_conversa, arquivo) if contexto: return contexto return "Não encontrei esse tema no material."

Parte 5 — Executando o agente

agente = AgenteDuvidas()pergunta = input("Digite sua dúvida: ")print(agente.responder(pergunta))

Parte 6 — Código completo

Copie todo o código abaixo para uma única célula do Google Colab e execute.

import jsondocumentos = [{ "titulo": "Estruturas de repetição", "conteudo": "Estruturas de repetição permitem executar comandos várias vezes." }, { "titulo": "Python", "conteudo": "Python é uma linguagem usada em IA." }]def recuperar_documento(pergunta): pergunta = pergunta.lower() documento_relevante = None for doc in documentos: if doc["titulo"].lower() in pergunta: documento_relevante = doc["conteudo"] return documento_relevantehistorico_conversa = []class AgenteDuvidas: def responder(self, pergunta): contexto = recuperar_documento(pergunta) historico_conversa.append(pergunta) with open("memoria.json", "w") as arquivo: json.dump(historico_conversa, arquivo) if contexto: return contexto

Parte 7 — Testando o agente

Resultados esperados:

- O que é Python? — Python é uma linguagem usada em IA.
- Como funciona estrutura de repetição? — Estruturas de repetição permitem executar comandos várias vezes.
- O que é API? — Não encontrei esse tema no material.
- O que é banco de dados? — Não encontrei esse tema no material.

O agente encontra respostas quando o título do documento aparece na pergunta. Caso contrário, apresenta a mensagem padrão.

Parte 8 — Visualizando a memória

Adicione e execute:

print(historico_conversa)

Resultado esperado:

["O que é Python?", "Como funciona estrutura de repetição?", "O que é API?", "O que é banco de dados?"]

O histórico registra as perguntas feitas. O arquivo `memoria.json` salva essas perguntas no ambiente do Colab.

Parte 9 — Reflexão

1. Qual a função da recuperação de contexto no agente?

Buscar informações relevantes nos documentos para responder às perguntas do usuário.

2. Qual a diferença entre RAG e memória de curto prazo?

O RAG recupera informações de uma base de documentos, enquanto a memória de curto prazo armazena o histórico da conversa.

3. O que acontece quando o agente não encontra um tema na base?

O agente retorna a mensagem: “Não encontrei esse tema no material.”